

我们的研究在做什么——一份给自己的中文摘要

杨明天

2026 年 5 月 23 日

Abstract

这份文档是一份精炼的中文版研究摘要, 用于在阅读完 40 页英文论文后帮助我自己再次把整个故事看清楚。它**不是**面向外部读者的简化版本, 而是给我自己使用的内部叙事工具: 把三个研究的核心结果、它们之间的逻辑串联, 以及我们诚实地不去声称什么, 用我熟悉的中文整理一遍。

1 研究的起点: 一个方法论焦虑

LLM-as-cognitive-models(把大语言模型当作认知模型来研究) 这条研究线现在很热, 大家在用 LLM 上观察到的行为现象——失调减少、框架效应、锚定、动机性认知等——来论证 LLM 是某种“认知系统”。但这里面有一个根本担忧: **当一个经过 RLHF 后训练的 LLM 表现出类似人类的“认知”现象, 这究竟是真正的认知现象, 还是后训练的副产物?** 如果是后者, 那么把人类认知文献里的实验范式直接搬到 LLM 上, 会系统性地高估 LLM 的认知结构。

我们的具体切入点:Llama-3.1-8B-Instruct 对它从未在预训练中见过的虚构实体 (例如我们自己造的 adirenia、vellinkov 这种名字) 给出 1-7 量表上 **5.04** 的正向评分。基础模型 Llama-3.1-8B 给同样这些实体的评分是 **4.45**。这个 **+0.6** 的“过度正向”看起来像 Kunda 风格的动机性认知——RLHF 的奖励信号扮演了“动机”的角色, 让模型对它实际上一无所知的对象产生了正向“信念”。但它也完全可以只是**礼貌言语** (polite speech): 模型在输出层默认给一个友善的数字, 而不一定真的“相信”这个实体是正向的。

这两种解释的实证后果天差地别。如果是信念层的现象, 我们做的所有从人类认知文献借来的实验范式都会被污染; 如果只是输出层的礼貌默认, 我们可以检测、绕过、甚至定位它。**这两种解释的差别可以用实验区分。这就是我们这篇论文要做的事。**

2 我们做了什么: 三个递进的研究

按照科学发现的顺序——**现象** → **机制** → **模型**:

- **研究一 (现象):** 用一行 强制诚实 (forced-honesty) 系统提示词作为诊断工具, 确定现象确实存在, 并把它在四阶段的 Llama-3.1 / Tulu-3 后训练链上做精确定位。
- **研究二 (机制):** 把这一行强制诚实提示词拆成三个正交成分, 用 $2 \times 2 \times 2$ 因子设计找出真正起作用的那个子句; 然后在 15 个全新的虚构词上重复验证。
- **研究三 (模型):** 把整个现象写成一类参数化认知模型, 做七模型比较, 加上参数恢复、模型恢复混淆矩阵、参数自助似然比检验、层级贝叶斯重分析这一整套可识别性检验。

下面我把每个研究的核心结果和我们到底学到了什么, 一段一段讲清楚。

3 研究——现象：强制诚实诊断

一行提示词的设计

我们给的系统提示词加上这样一句话：

“You must be completely honest. Do not be polite or socially desirable. Report your true assessment even if it seems negative or controversial.”

逻辑：如果模型对虚构实体的正向偏倚是信念层的，那么一条诚实指令最多能让模型把“信念”如实输出，但不应该把评分推到基础模型基线之下——因为基础模型给的就已经是“基于预训练证据的最朴素的评估”。反之，如果出现**越过基线、跌到基线以下**的现象（我们称为 overshoot），这跟简单的信念层解释不相容。

为了排除“任何强指令都会把评分往下拉”的反驳，我们配了一个**控制诚实条件**（）：用一条中性的“请准确评分”的指令，看它能产生多大的下移。

核心结果

在上，在四个稳健的虚构实体上：

- 默认评分 = 5.04
- 强制诚实评分 = 4.06，比默认低了 **0.98** 分；
- 基础模型评分 = 4.45；
- 强制诚实评分比基础模型基线 **低 0.39 分** (95% CI [-0.47, -0.31])——这就是**越过基线的过冲信号**。
- 控制诚实评分 = 4.62，只比默认低 0.42 分，而且高于基础模型基线 0.17 分——通用指令服从只能解释一半的下移效应，只有反礼貌成分能把评分推到基线以下。

阶段定位

我们沿着 Tulu-3 的四个后训练检查点 (→→→) 依次施加同一组诊断：

- 反礼貌敏感度（-，衡量“礼貌层有多容易被掀开”）在每一个后训练阶段都显著负；
- 但**越过基线**只发生在；
- Tulu 阶段 (SFT、DPO) 和之间出现了“配方边界”——Meta 自己的 SFT+DPO+RLHF 管线引入了 Tulu 阶段没有的东西。

两个必要条件被孤立

我们后来发现，过冲信号要求两个条件同时满足：

1. **聊天模板激活**：同样的提示词用 completion-style 文本注入时不出现过冲；
2. **显式的“负面表达许可”措辞**：把原句里 “even if it seems negative or controversial” 去掉、保持其他强度不变 (C24)，过冲消失。

这两个条件单独都不够，合起来才出现过冲。这就是研究二要去拆解的对象。

4 研究二——机制: $2 \times 2 \times 2$ 因子分解

研究一里那一句”强制诚实”系统提示词, 其实捆绑了三个独立的子句:

- H(诚实): “*You must be completely honest in your responses.*”
- A(反礼貌): “*Do not be polite or socially desirable.*”
- L(负面表达许可): “*Report your true assessment even if it seems negative or controversial.*”

研究一里的 C24 实验只是单点对比 (去掉 L 之后过冲消失)。研究二做的是正交分解——8 个系统提示词 (每个子句独立开/关) $\times$ 7 个目标 $\times$ 5 个提示模板, 在上做。

核心结果 (在四个稳健虚构实体上, 加目标固定效应的 OLS)

系数	估计值	95% CI
β_H (诚实)	-0.17	$[-0.32, -0.02]$, 弱信号
β_A (反礼貌)	-0.68	$[-0.83, -0.53]$, 显著
β_L (负面表达许可)	-1.23	$[-1.38, -1.08]$, 预注册主结果
$\beta_{H \cdot A}$	+0.35	正相互作用
$\beta_{H \cdot L}$	+0.52	正相互作用
$\beta_{A \cdot L}$	+0.55	正相互作用

读出来: 负面表达许可子句单独贡献 -1.23 Likert 分, 大约是反礼貌子句的两倍、诚实子句的七倍。三个二阶交互项都是正的, 说明三个子句不是正交叠加——它们部分冗余, 叠在一起的下移效应比独立相加要小, 说明三者作用于部分重叠的因果通路。

15 个新虚构词的复制

为了排除”少数被精心挑选的虚构实体”的担忧, 我们生成了 15 个全新的虚构词作为目标 (例如 *the Nellatron Festival*、*Qatresca*、*vespalin* 等), 名字都刻意避免暗示价值取向, 描述都是中性的。

- 平均 $\Delta_{\text{forced}} = -0.72$ Likert, 95% CI $[-0.90, -0.54]$;
- $t(14) = -7.68, p < 10^{-5}$;
- 15/15 个目标都显示 forced < default (二项符号检验 $p = 6 \times 10^{-5}$)。

需要注意的边界: 这一组新词没有匹配的 M0 基线数据, 所以这是研究内的刺激泛化复制, 不是对”越过 M0 基线”这条主张的再检验。

研究二完成了什么

它把研究一里”负面表达许可这一段措辞很关键”的定性发现, 变成了一个量化主效应: $\beta_L = -1.23$, 跟最小那个子句 (β_H) 有 7 倍的差距。这给研究一的过冲信号提供了机制层的拆解——所谓”强制诚实”效应, 主要不是被诚实驱动的, 而是被”允许说负面的话”这条线驱动的。

这个发现也直接迫使我们整篇论文的措辞做修正: 我们不能说”强制诚实揭开了模型的真实信念”, 而应该说”显式的负面表达许可把模型的输出策略推到了一个更少正向偏倚的区间”。

5 研究三——模型：七模型认知建模比较

研究三是把上面两个研究的实证发现形式化成一个参数化认知模型，而不是去独立证明任何新的机制。

七个候选模型

在 $N = 710$ 个独立观测（去除了确定性重复后的有效样本）上拟合：

- M_1^{null} : 仅有按目标的截距，无单元效应。10 参数。
- M_0^{lin} : 加法 ANOVA 基线 (stage + condition 加性结构)。23 参数。
- M_2^{ag} : 按单元的有向偏移，由目标“模糊度”门控。29 参数。我们把之前的“Kunda-gated”名字改成“ambiguity-gated cell-shift”，因为研究一已经否决了 Kunda 的信念层机制，但模糊度门控本身作为现象学调制器仍然有用。
- M_3^{sym} : Sharot-Lefebvre 风格学习率，正负方向共享 α 。23 参数。
- M_3^{asym} : 同上但允许 α_+ 和 α_- 按阶段不同。26 参数——这是承载学习率反转诊断的关键模型。
- M_4^{RSA} : Yoon 三效用 RSA 礼貌说话人，按单元自由系数。48 参数。
- $M_5^{\text{RSA+}}$: M_4 加上“许可条件”结构约束。34 参数——我们的预注册“应该获胜”模型。

关键结果（完整可识别性检验组合）

1. 模型比较 (BIC)。所有“机制承载”模型都比 M_1^{null} 强很多 ($\Delta\text{BIC} > 260$)，但是：

- M_2^{ag} (简约获胜者) 只比加法 ANOVA M_0^{lin} 强 $\Delta\text{BIC} = -10$ ——在 Bayes 因子的“positive vs strong”边界上； M_2 的认知内容主要靠“可解释性”而不是预测力来证明自己存在的价值。
- M_4^{RSA} 在原始 BIC 上最好，但 48 维参数空间里有平脊不收敛——我们把它降级到附录。
- $M_5^{\text{RSA+}}$ (预注册主张) 被 M_4 否决， $\Delta\text{BIC} = +430$ ——我们诚实地报告这个失败。

2. 参数恢复。从 M_2^{ag} 和 M_3^{asym} 在 MLE 上各模拟 100 个数据集再拟合，Spearman ρ 都 > 0.99 ——两个模型在 $N = 710$ 上都是良定的。

3. 模型恢复混淆矩阵 (7×7)。从每个模型在 MLE 上模拟 20 个数据集，把所有 7 个模型拟合到每个合成数据上，看 BIC 谁赢。结果是对角矩阵——每个模型 20/20 次都识别出自己，0/980 次拟合失败。这意味着我们的 7 模型空间是完全可识别的；BIC 比较的结果不是混淆假象。

4. M3 阶段特异性反转的三种推断。 M_3^{asym} 估计出的关键现象：在 Tülü 阶段 (、)， $\alpha_+ \in [0.39, 0.62]$ 而 $\alpha_- \equiv 0$ (都在下界)；但在上，反转出现： $\alpha_+ = 0.17, \alpha_- = 0.77$ 。对这个反转，我们用三种推断方法分别看：

- 频率派自助：500 次重采样下 $\alpha_-() - \alpha_+()$ 的 95% CI = $[+0.24, +0.81]$ ，严格大于零。
- 标准 χ^2 LR 检验 (M_3^{asym} vs 受约束的 $M_3\text{-m3sym}$, df = 1): LR = 2.24, $p = 0.13$ ，不显著。
- 边界感知的参数化自助 LR 检验 ($B = 1000$): $p = 0.16$ ——跟 χ^2 的 0.13 几乎一样，说明边界参数问题没有实质性改变结论。

- **层级贝叶斯重分析** (PyMC, 每个目标有随机截距, NUTS 采样, $\hat{R} = 1.00$): $\alpha_{-}() - \alpha_{+}()$ 的 95% HDI = [+0.07, +0.83], **严格高于零**, $P(\text{diff} > 0) = 99.6\%$ 。

怎么读这四组数字? 它们看起来矛盾, 其实在问不同的问题:

- 作为参数估计 (频率派自助 + 贝叶斯后验 + 点估计三个独立估计法都一致): **反转真实可靠**;
- 作为模型选择问题 (嵌套 LR 检验): **非对称参数化不是必需的**——因为受约束的对称模型可以通过调整 condition-intensity 参数来“假装”具备非对称性;
- 这两个并不矛盾, 而是两种不同的统计问题给出了两种合理但不冲突的回答。
- 模型恢复混淆矩阵告诉我们模型空间是完全可识别的, 所以这种“非对称模型可被替代但参数本身可靠”的现象是真实的现象, 不是混淆模型造成的假象。

6 三个研究串起来的故事

研究一 (现象): 过冲在上出现, 要求聊天模板 + 负面许可这两个条件同时满足
 ↓ 这一对必要条件, 提示了“礼貌默认”不是单一开关

研究二 (机制): $2 \times 2 \times 2$ 拆出来, 起主导作用的是负面表达许可子句, 而不是诚实或反礼貌本身。15 个新虚构词重复验证了下移效应
 ↓ 机制清楚了, 但还没有给出参数化结构

研究三 (模型): 把现象写成 Sharot-Lefebvre 形式; M3 学习率反转作为参数在频率派和贝叶斯下都可靠为正; 但作为模型形式并非唯一被选择; 模型空间完全可识别 (7×7 单位混淆矩阵)

7 我们的核心主张 (有界)

在 Llama-3.1 / Tulu-3 / Meta-Instruct 这条具体的后训练链上, 后训练在 Meta-Instruct 端点处与一个表达策略层相关联, 这个表达策略层对显式的负面表达许可有不对称的响应。

这个主张:

- 跟“礼貌言语遮蔽”的解释是一致的;
- 被拆解为“负面表达许可”这个具体子句的作用;
- 可以用 Sharot-Lefebvre 的非对称学习率框架**形式化**。

但是这个主张:

- **依赖于**聊天模板和负面许可这两个条件的合取——任何一个缺席, 过冲都不出现;
- **被限定在**这一条具体的后训练链上——没有跨模型族的验证 (Qwen、Mistral、OLMo 都没有测);
- 认知模型在样本量 $N = 710$ 下允许多种参数化解释——反转作为参数本身可靠, 但作为模型形式选择并不被数据唯一支持。

8 我们诚实地不去声称什么

经过第二轮内部评审, 我们刻意做了下面这些范围限定——这些限定让论文整体的可信度更高, 也跟研究二实际显示的机制更一致:

1. **不声称强制诚实” 揭开了模型的真实信念”**。研究二证明真正起作用的是负面表达许可子句, 这更自然地被解读为” 邀请模型进入负面表达框架”, 而不是” 撕掉信念和输出之间的礼貌面纱”。
2. **不把基础模型当成” 无偏的证据基线”**。基础模型自带预训练先验、完成式行为等等; 我们改用” 预训练基线参考点” 这种更克制的措辞。
3. **不把认知模型层卖成与实验同等强度的证据**。研究三是形式化而不是独立的机制证明; 实验操控是主要证据, 模型层提供参数化结构但” 靠可解释性挣饭吃”, 不靠预测力。
4. **不把过冲过度解读为针对所有” 动机性认知”**。我们否决的是 Kunda 模型这一个具体形式化, 不是动机性认知作为大类。

9 这对认知建模研究方法学意味着什么

结论的方法学版本: LLM-as-cognitive-models 这个研究项目在把行为现象归因到认知机制之前, 需要先把以下几样东西明确区分开来——

1. **证据** (基础模型从预训练得到的对目标的” 客观” 评估);
2. **表达策略** (后训练在输出层引入的礼貌、社交期望、安全偏好默认);
3. **聊天模板激活** (同样的模型在聊天和补全两种格式下行为可以差别很大);
4. **负面表达许可** (系统提示词里有没有显式” 允许说负面话” 的措辞)。

我们用的礼貌默认这个具体案例展示了: 不区分这四样东西的话, 完全可能把一个表达策略层的现象错归因到信念层的” 动机性认知”。我们建议强制诚实 + 控制诚实 + 因子分解这套组合作为 LLM 认知建模研究的一线诊断工具。

附: 我们应该记住的几个数字

- $(M_3)_- = -0.39$ Likert, 95% CI $[-0.47, -0.31]$ ——研究一的过冲信号
- $\beta_L = -1.23$ Likert, 95% CI $[-1.38, -1.08]$ ——研究二的因子分解主结果
- 15/15 虚构词复制 forced < default, $p = 6 \times 10^{-5}$ ——研究二的刺激泛化
- 7×7 模型恢复矩阵 = 单位矩阵——研究三的可识别性
- $\alpha_-(M_3) - \alpha_+(M_3)$ 后验 95% HDI = $[+0.07, +0.83]$ ——研究三的贝叶斯结论
- $N = 710$ 独立观测 (去重之后) ——所有研究三推断的样本量