

强制诚实指令分离大语言模型评分偏差中的输出策略与信念偏移

小组 7

杨明天舒哲涵

摘要

将大语言模型作为认知模型的研究面临一个欠定问题：模型的行为输出反映的是内部表征还是输出层的表达策略，仅凭观测拟合无法区分。本研究以 Llama-3.1-8B 后训练链条的四个检查点 (C_0 基座 $\rightarrow C_1$ SFT $\rightarrow C_2$ DPO $\rightarrow C_3$ Instruct) 为对象，用对数概率读出 1-7 分期望评分，设计了强制诚实系统提示作为诊断工具。结果发现， C_3 端的评分较基座低 0.39 分 (95% CI $[-0.47, -0.31]$)，Tulu 子链各阶段均未出现该过冲，表明低于基线的矫枉过正仅存于 Meta RLHF 配方。本文进一步将竞争性理论（动机性推理与语用礼貌）转化为九个认知模型，以留出交叉验证为首要判据进行比较。RSA 礼貌言者模型在 BIC 与交叉验证上均大幅领先；歧义门控机制被明确证伪（去门版 $\Delta BIC = 32$ ）；符号不对称 RLHF 反转作为点估计模式稳健但非结构必需。实验与建模共同指向输出策略账户。

1 引言

大语言模型 (LLMs) 经指令微调与 RLHF 后，行为表现出系统的社会偏好 [Ouyang et al., 2022, Lambert et al., 2024]。在本研究中，一个具体表现是：Llama-3.1-8B-Instruct 对虚构对象（如 *adirenia*、*vellinkov*）给出比基座模型高约 0.6 个李克特分的好感评分。

这一现象处于“将 LLMs 作为认知模型” [LLMs-as-cognitive-models; Binz and Schulz, 2022] 研究纲领的核心张力点上。该纲领的基本逻辑是：若模型行为能被人类认知的构念，如动机性推理 [Kunda, 1990] 和乐观偏差 [Sharot et al., 2011]，所刻画，研究者便有可能从行为反推模型的内部表征。然而，这一逻辑存在一个未被充分处理的欠定问题：同一条行为曲线，既可来自表征层的信念偏移（模型对这些对象的内部态度确实更正面了），也可来自输出层的表达策略（模型学会了在社交上更得体的回答方式）。不加区分地将信念层模型拟合到输出层效应上，会导致系统性的过度归因。

既有研究已从不同角度触及这一问题。Itzhak et al. [2023] 发现了指令微调引发的认知偏差，但未提供分离表达与信念的诊断工具；Murthy et al. [2025] 通过拟合礼貌言语模型推断 RLHF 后的价值权衡变化，但其依据来自模型选择而非直接的实验操纵；Lehr et al. [2025] 在 GPT-4o 上观察到类人认知失调行为，但关注点不在偏差的层面归属。上述工作均未直接回答：正向偏差位于表征层还是输出层。Lambert et al. [2024] 释放了同一基座上 SFT 和 DPO 的中间检查点，使沿后训练链条逐段测量成为可能，突破了既往的单一二元对比。

本研究起源于对 Lehr et al. [2025] 的一次失败复现，未重现目标效应，却稳定观察到上述“陌生即好评”的正向偏差。问题由此转向：这 0.6 分是可被一条指令揭去的输出策略，还是模

型内部真实的态度转变？为此，本文设计了强制诚实诊断：给模型一条“请诚实、不必客气、可以说负面”的系统提示：若偏差只是输出层礼貌面具，揭去后评分应跌至基座以下；若是信念偏移，仅要求诚实不应跌破基线。在此基础上，本文完成三项工作：（1）在四个后训练检查点上运行强制诚实诊断及 $2 \times 2 \times 2$ 因子分解，定位过冲出现的阶段和提示中的活性成分；（2）构建模块化生成方程，将动机性推理与语用礼貌两类竞争性理论转化为可拟合的认知模型；（3）以留出交叉验证为首要判据进行模型比较，明确报告被证伪的机制。

2 方法

2.1 数据读出

每次试次直接读取评分数值 token “1”–“7” 的对数概率，经 softmax 归一化后计算期望评分 $E[\text{rating}] = \sum_{i=1}^7 i \cdot p(i)$ ，其中 $p(i) = \exp(\text{logit}_i) / \sum_j \exp(\text{logit}_j)$ 。该读出方式无采样噪声，期望评分是取值于 $[1, 7]$ 的连续量，作为全部后续建模的因变量。

2.2 后训练检查点

沿 Llama-3.1-8B 取四个检查点（以 C 标记，以区别于后文的认知模型）： C_0 = 基座； C_1 = Tulu-3-8B-SFT（AllenAI 监督微调）； C_2 = Tulu-3-8B-DPO（直接偏好优化）； C_3 = Llama-3.1-8B-Instruct（Meta 完整 SFT+DPO+RLHF）[Lambert et al., 2024]。 $C_0 \rightarrow C_1 \rightarrow C_2$ 为配方内因果有效的 Tulu 子链； $C_2 \rightarrow C_3$ 为配方切换，其间差异不具因果推断效力。

2.3 强制诚实诊断

核心实验操纵为一对系统提示：（a）强制诚实：“请诚实、不必客气、可以说负面”；（b）控制诚实：仅要求诚实，不含反礼貌措辞。将提示进一步拆为“要求诚实 $\times$ 反对礼貌 $\times$ 允许负面”的 $2 \times 2 \times 2$ 被试内因子设计，以定位活性成分。

2.4 去重

原始约 7,700 试次（每格 5 模板 $\times$ 10 重复）。因贪婪解码且固定单种子，同模板 10 次重复产生逐位相同对数概率。按（对象, 格, 模板）去重后， $N = 710$ 。

3 行为结果

强制诚实实在 C_3 端将虚构对象评分压至低于 C_0 基线 0.39 分（95% CI $[-0.47, -0.31]$ ），控制版不产生过冲（图 1）。因子分解显示“允许负面”效应量最大（ $\beta = -1.23$ ），在 15 个全新伪词上 15/15 一致为负（ $p < 10^{-5}$ ）。

逐阶段定位进一步收紧推论空间。Tulu 子链两端（ C_1, C_2 ）强制诚实评分均位于基线以上（ C_1 : $+0.24$ $[0.13, 0.34]$, C_2 : $+0.34$ $[0.22, 0.44]$ ），未出现过冲。过冲仅在 C_3 被观测到，表明 SFT+DPO 未独立安装该输出策略。“跌破基线”是一个关键信息节点：若偏差是信念变正，强制诚实最多压回基线水平，不应跌破。过冲表明模型习得的并非对这些对象的正向信念，而是可被指令揭去、矫枉过正的输出表达惯例。




图 1: 强制诚实与控制诚实四检查点上的对比。C₃ 端强制诚实跌破基线；C₁、C₂ 无过冲。误差线为 95% 自助法 CI。

以上行为结果排除了动机性认知，但尚未确定替代机制的形式：是简单格子偏移、歧义门控残余、还是系统语用推理。区分这些需要形式化模型：将竞争性理论转化为可拟合、可比较的数学结构，让数据裁决机制的有无与必要性。

4 认知模型

4.1 模块化生成方程

所有模型以高斯似然在试次层拟合期望评分，L-BFGS-B 多起点优化。记 b_t 为对象 t 的自由截距。九个模型统一表达为：

$$\mu(t, s, c) = b_t + f_{\text{shift}}(s, c) \cdot g(b_t), \quad (1)$$

f_{shift} 为格子偏移函数， g 为可选门控。不同模型通过约束二者的功能形式来定义（表 1）。

4.2 Kunda 族：歧义门控与消融

Kunda [1990] 关于动机性推理的核心论断是“证据最模糊时最易被动机推动”。Kunda 模型将这一直觉实现为： $f_{\text{shift}} = \delta_{s,c}$ （每格自由偏移）， $g(b_t) = \frac{4(b-1)(7-b)}{36}$ 为开口向下的二次门（ $b = 4$ 处峰值 1）。其可检验约束在于：同一 $\delta_{s,c}$ 跨对象共享，仅被各对象的歧义程度调制。Kunda-nogate ($g \equiv 1$, 去门) 和 Kunda-freegate (门峰位 p 与宽度 w 自由) 直接检验该约束。

表 1: 模型定义。 k 为自由参数数 (含 b_t 与 σ)。

模型	$f_{\text{shift}}(s, c)$	$g(b_t)$	k
Null (零模型)	0	1	10
Add (加性基线)	$\beta_s + \gamma_c$	1	23
Kunda (歧义门控)	$\delta_{s,c}$	$\frac{4(b-1)(7-b)}{36}$	29
Kunda-nogate	$\delta_{s,c}$	1	29
Kunda-freegate	$\delta_{s,c}$	$\exp(-(b-p)^2/2w^2)$	31
Asym (符号不对称)	$\text{sign} \cdot \alpha(s, \text{dir}) \cdot I(c)$	同 Kunda	26
Asym-sym (对称对照)	$\text{sign} \cdot \alpha(s) \cdot I(c)$	同 Kunda	23
RSA (礼貌言者)	$\omega_{\text{pos}} \cdot 7 + \omega_{\text{neg}} \cdot 1 + (\omega_{\text{inf}} - 1)b_t$	1	48
RSA-cond (许可条件)	同 RSA, ω_{neg} 约束为 ANOVA	1	34

4.3 Asym 族：静态符号不对称敏感度

人类存在乐观偏差：在强化学习任务中，个体对正性预测误差的学习率 α_+ 高于对负性预测误差的学习率 α_- [Sharot et al., 2011, Lefebvre et al., 2017]。需明确指出，Sharot et al. [2011] 与 Lefebvre et al. [2017] 的原始模型是序贯 Rescorla-Wagner 更新的学习率参数；本研究每次评分是独立前向传播，无试次间结果反馈，真正的 RW 更新在结构上不适用。但乐观偏差的计算后果，即对正、负效价信息的不对称敏感性，并不天然依赖序贯更新过程。将序贯 RL 更新中的核心计算特征（不对称敏感度）从其算法载体（试次间误差修正）中分离出来，单独检验前者在 LLM 推理中是否存在，是将认知构念迁移到语言模型时的方法论前提。本文借此检验这一分离是否成立，而非声称实现了原 RL 模型。

Asym 将这一抽象实现为 $f_{\text{shift}} = \text{sign}(c) \cdot \alpha(s, \text{dir}(c)) \cdot I(c)$ ，其中 $\alpha(s, \pm)$ 为阶段 s 的静态敏感度（非学习率）， $I(c)$ 为条件强度（默认条件锚定为 1）。效价方向 $\text{dir}(c)$ 由提示设计先验确定：含反礼貌措辞为负向，其余为正向。该先验表独立于观测均值，消除了从数据反推符号的循环性。Asym-sym 为嵌套对称对照 ($\alpha_+(s) = \alpha_-(s) \equiv \alpha(s)$)， $\Delta df = 3$ 的似然比检验)。

4.4 RSA 族：礼貌言语的形式化

RSA 框架 [Frank and Goodman, 2012, Yoon et al., 2020] 将说话人建模为在多效用间做 softmax 选择的理性行动者。本研究将其连续化以适应李克特输出：每格预测评分为三个“拉力”的 softmax 加权混合，分别拉向真相 b_t 、正向社交锚（“客气”， $H_{\text{pos}} = 7$ ）、负向社交锚（“直率”， $H_{\text{neg}} = 1$ ）。RSA 为每格自由权重（48 参）；RSA-cond 将负向权重约束为“对话模板 $\times$ 允许负面”的 2×2 方差分析形式。


5 模型比较

5.1 拟合与泛化

表 2 报告九个模型的 BIC 与 10 折分层交叉验证 (CV) 留出对数似然。分层按（阶段，条件）格内均匀分配试次至 10 折。本研究以留出预测为首要判据。BIC 可被参数填充以提高，留出似然则不能。参数恢复 Spearman $\rho > 0.99$ ，模型恢复混淆矩阵对角，表明模型彼此可区分。

表 2: 模型比较 ($N = 710$)。BIC 越小越好；CV 留出对数似然越接近 0 越好。最优值加粗。

模型	k	BIC	CV 留出 $\log \mathcal{L}$
RSA	48	870.6	-319.8
Kunda-nogate	29	1241.8	-553.6
Kunda-freegate	31	1249.0	-549.5
Kunda	29	1274.1	-566.1
Add	23	1284.2	-587.0
RSA-cond	34	1300.5	-571.9
Asym	26	1401.0	-632.2
Asym-sym	23	1441.6	-661.6
Null	10	1717.7	-835.1

图 2: 符号不对称敏感性的诊断。(A) 各阶段的 α_+ 与 α_- (自助法 95% CI): SFT/DPO 仅正向敏感, Instruct 翻转为负向敏感占优。(B) 逐阶段不对称量 $\alpha_- - \alpha_+$ 。(C) 参数恢复 (真值 vs. 回拟均值)。

RSA 在 BIC 与 CV 上同时大幅领先, CV $\Delta \log \mathcal{L}$ 相对于次优模型为 +233.8, 与行为诊断方向一致。但 RSA 的 48 参较为灵活, 优势部分来源于刻画能力; 在近似简约度下, 模型比较不能独立裁决两类账户; 真正打破平衡的是强制诚实实验中低于基线的过冲。

5.2 歧义门被证伪

Kunda-nogate (BIC = 1241.8) 在 BIC 上优于 Kunda (BIC = 1274.1), CV 同向 (-553.6 vs. -566.1)。Kunda-freegate (BIC = 1249.0, CV -549.5) 介于两者之间, 未显著优于去门版。这一结果表明 Kunda [1990] “歧义处最可塑”的具体机制不被数据需要, 去掉门后模型反而更优。

5.3 符号不对称: 稳健模式, 非必需结构

在先验效价下, Asym 的敏感度估计为: C_1 (SFT) $\alpha_+ = 0.48$, $\alpha_- \approx 0$; C_2 (DPO) $\alpha_+ = 0.73$, $\alpha_- \approx 0$; C_3 (Instruct) 反转为 $\alpha_- = 1.36 \gg \alpha_+ = 0.26$ (图 2)。即 SFT/DPO 阶段仅对正向线索敏感, RLHF 阶段翻转为对负面许可高度敏感。

该不对称性整体上相对于 Asym-sym 高度显著 (LR = 60.3, $df = 3$, $p < 0.001$), 但主要由 C_1 、 C_2 的单侧乐观所驱动。当检验聚焦于 C_3 单阶段 (令 C_3 的 $\alpha_+ = \alpha_-$, 保留 C_1 、 C_2 自由) 时, LR ≈ 0 ($p \gg 0.05$), 且 $\alpha_-(C_3)$ 与 $I(c)$ 存在可辨识性混淆。

这一结果为 RSA 的胜出提供了一种计算解释：RLHF 反转可能并非需要独立参数的“结构”，而是柔性语用推理在 RLHF 数据中学习到的涌现性质。该反转作为点估计模式稳健（自助法 CI 排除 0），但数据不强制它作为独立的模型组件。

后验预测检验中， C_3 -forced 减 C_0 -default 过冲观测为 -0.356 ，模拟 95% CI $[-0.83, -0.19]$ ，2000 次模拟 100% 产生负向过冲（格层 $R^2 = 0.98$ ），模型确能再生“跌破基线”这一关键定性签名。

6 讨论

本文的实验与计算证据共同收敛于一个结论：后训练 LLM 对虚构对象的正向评分偏差，其占优账户是输出层的表达策略，而非表征层的信念偏移。在实验端，强制诚实诊断使评分跌破基线，逐阶段定位表明过冲仅存于 Meta RLHF 配方；在计算端，RSA 礼貌言者以 $\Delta BIC > 400$ 和 $CV \Delta \log \mathcal{L} = +233.8$ 领先所有动机认知模型，歧义门控被明确证伪。建模的效用在于将描述性现象翻译为可检验的机制语言：“后训练到底改了什么”从看平均分差异，变为用模型刻画候选机制、用留出预测去裁决。

本研究存在若干局限。其一，使用模型自生成数据而非人类数据，对认知建模本身无方法论贡献。其二，全部模型均为静态结构，Asym 借用了乐观偏差的不对称母题但不包含真正的序贯更新，已在命名上严格区分。其三，RSA 较为灵活，其优势部分来源于刻画能力。其四，证据限于单一模型族与单一评分范式。本文保留了两项负结果（歧义门被证伪、Asym 反转非结构必需），未将其淡化为稳健性检验。在认知建模中，证伪一个被明确预测的机制与确认一个机制具有同等的证据价值；诚实地报告“数据不要求这个机制”，比将数据事后合理化以支撑一个漂亮的机制叙事，是更负责任的做法。

参考文献

- Anonymous Authors. Stage a: Behavioral replication of the lehr 2025 free-choice moderator on llama-3.1-8b-instruct, 2026. Internal experiment record.
- Daryl J. Bem. Self-perception: An alternative interpretation of cognitive dissonance phenomena. *Psychological Review*, 74(3):183–200, 1967. doi: 10.1037/h0024835.
- Marcel Binz and Eric Schulz. Using cognitive psychology to understand gpt-3. *PNAS*, 2022. doi: 10.1073/pnas.2218523120.
- Marcel Binz and Eric Schulz. Turning large language models into cognitive models. In *ICLR 2024*, 2023. doi: 10.48550/arXiv.2306.03917.
- Marcel Binz, Elif Akata, Matthias Bethge, Franziska Brandle, Frederick Callaway, Julian Coda-Forno, Peter Dayan, Can Demircan, Maria K. Eckstein, No’emi ’EltetHo, Thomas L. Griffiths, Susanne Haridi, A. Jagadish, Ji-An Li, Alex Kipnis, Sreejan Kumar, Tobias Ludwig, Marvin Mathony, Marcelo G. Mattar, Alireza Modirshanechi, Surabhi S. Nath, Joshua C. Peterson, Milena Rmuš, Evan M. Russek, Tankred Saanum, Natalia Scharfenberg, Johannes A.

- Schubert, Luca M. Schulze Buschoff, Nishad Singhi, Xin Sui, Mirko Thalmann, F. Theis, Vuong Truong, Vishaal Udandaraao, Konstantinos Voudouris, Robert C. Wilson, Kristin Witte, Shuchen Wu, Dirk U. Wulff, Huadong Xiong, and Eric Schulz. Centaur: a foundation model of human cognition. *Nature*, 2024. doi: 10.48550/arXiv.2410.20268.
- Julian Coda-Forno, Marcel Binz, Jane X. Wang, and Eric Schulz. Cogbench: a large language model walks into a psychology lab. In *ICML 2024*, 2024. doi: 10.48550/arXiv.2402.18225.
- Leon Festinger. *A Theory of Cognitive Dissonance*. Stanford University Press, Stanford, CA, 1957.
- Michael C. Frank and Noah D. Goodman. Predicting pragmatic reasoning in language games. *Science*, 336(6084):998, 2012.
- Valentin Hofmann, Pratyusha Kalluri, Dan Jurafsky, and Sharese King. Dialect prejudice predicts ai decisions about people’s character, employability, and criminality. *Nature*, 2024. doi: 10.48550/arXiv.2403.00742.
- Itay Itzhak, Gabriel Stanovsky, Nir Rosenfeld, and Yonatan Belinkov. Instructed to bias: Instruction-tuned language models exhibit emergent cognitive bias. *Transactions of the Association for Computational Linguistics*, 2023. doi: 10.1162/tacl_a_00673.
- Robert E. Kass and Adrian E. Raftery. Bayes factors. *Journal of the American Statistical Association*, 90(430):773–795, 1995. doi: 10.1080/01621459.1995.10476572.
- Ziva Kunda. The case for motivated reasoning. *Psychological Bulletin*, 108(3):480–498, 1990. doi: 10.1037/0033-2909.108.3.480.
- Nathan Lambert, Jacob Daniel Morrison, Valentina Pyatkin, Shengyi Huang, Hamish Ivison, Faeze Brahman, Lester James Validad Miranda, Alisa Liu, Nouha Dziri, Xinxi Lyu, Yuling Gu, Saumya Malik, Victoria Graf, Jena D. Hwang, Jiangjiang Yang, Ronan Le Bras, Oyvind Tafjord, Christopher Wilhelm, Luca Soldaini, Noah A. Smith, Yizhong Wang, Pradeep Dasigi, and Hanna Hajishirzi. Tülu 3: Pushing frontiers in open language model post-training. *arXiv preprint*, 2024. doi: 10.48550/arXiv.2411.15124.
- Germain Lefebvre, Maël Lebreton, Florent Meyniel, Sacha Bourgeois-Gironde, and Stefano Palminteri. Behavioural and neural characterization of optimistic reinforcement learning. *Nature Human Behaviour*, 1(4):0067, 2017. doi: 10.1038/s41562-017-0067.
- Steven A. Lehr, K. S. Saichandran, Eddie Harmon-Jones, Nykko Vitali, and M. Banaji. Kernels of selfhood: Gpt-4o shows humanlike patterns of cognitive consistency moderated by free choice. *PNAS*, 2025. doi: 10.48550/arXiv.2502.07088.
- Haoyang Lu, Li Yi, and Hang Zhang. Autistic traits influence the strategic diversity of information sampling: Insights from two-stage decision models. *PLOS Computational Biology*, 15(12):e1006964, 2019. doi: 10.1371/journal.pcbi.1006964.

- Kyle Mahowald, Anna A. Ivanova, I. Blank, Nancy Kanwisher, Joshua B. Tenenbaum, and E. Fedorenko. Dissociating language and thought in large language models: a cognitive perspective. *Trends in Cognitive Sciences*, 2023. doi: 10.1016/j.tics.2024.01.011.
- R. Thomas McCoy, Shunyu Yao, Dan Friedman, Matthew Hardy, and Thomas L. Griffiths. Embers of autoregression: Understanding large language models through the problem they are trained to solve. *PNAS*, 2023. doi: 10.48550/arXiv.2309.13638.
- Sonia K. Murthy, Rosie Zhao, Jennifer Hu, S. Kakade, Markus Wulfmeier, Peng Qian, and Tomer D. Ullman. Cognitive models can reveal interpretable value trade-offs in language models. *arXiv preprint*, 2025.
- Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, John Schulman, Jacob Hilton, Fraser Kelton, Luke Miller, Maddie Simens, Amanda Askell, Peter Welinder, Paul Christiano, Jan Leike, and Ryan Lowe. Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35:27730–27744, 2022.
- Xu Pan, Jingxuan Fan, Zidi Xiong, Ely Hahami, Jorin Overwiening, and Ziqian Xie. User-assistant bias in llms. *arXiv preprint*, 2025. doi: 10.48550/arXiv.2508.15815.
- Matthew Riemer, Zahra Ashktorab, Djallel Bouneffouf, Payel Das, Miao Liu, Justin D. Weisz, and Murray Campbell. Position: Theory of mind benchmarks are broken for large language models. In *ICML 2024*, 2024.
- Milena Rmuš, A. Jagadish, Marvin Mathony, Tobias Ludwig, and Eric Schulz. Generating computational cognitive models using large language models. In *NeurIPS 2025*, 2025.
- Steven G. Self and Kung-Yee Liang. Asymptotic properties of maximum likelihood estimators and likelihood ratio tests under nonstandard conditions. *Journal of the American Statistical Association*, 82(398):605–610, 1987. doi: 10.1080/01621459.1987.10478472.
- Mrinank Sharma, Meg Tong, Tomasz Korbak, D. Duvenaud, Amanda Askell, Samuel R. Bowman, Newton Cheng, Esin Durmus, Zac Hatfield-Dodds, Scott Johnston, Shauna Kravec, Tim Maxwell, Sam McCandlish, Kamal Ndousse, Oliver Rausch, Nicholas Schiefer, Da Yan, Miranda Zhang, and Ethan Perez. Towards understanding sycophancy in language models. *arXiv preprint*, 2023. doi: 10.48550/arXiv.2310.13548.
- Tali Sharot, Christoph W. Korn, and Raymond J. Dolan. How unrealistic optimism is maintained in the face of reality. *Nature Neuroscience*, 14(11):1475–1479, 2011. doi: 10.1038/nn.2949.
- Nicholas Sofroniew, Isaac Kauvar, William Saunders, Runjin Chen, Tom Henighan, Sasha Hy-drie, Craig Citro, Adam Pearce, Julius Tarnig, Wes Gurnee, Joshua Batson, Sam Zimmerman,

- Kelley Rivoire, Kyle Fish, Chris Olah, and Jack Lindsey. Emotion concepts and their function in a large language model. *arXiv preprint arXiv:2604.07729*, 2026. Preprint; cited for interpretability precedent on representation-level emotion concepts.
- Taylor W. Webb, K. Holyoak, and Hongjing Lu. Emergent analogical reasoning in large language models. *Nature Human Behaviour*, 2022. doi: 10.1038/s41562-023-01659-w.
- Alexander Wei, Nika Haghtalab, and J. Steinhardt. Jailbroken: How does llm safety training fail? In *NeurIPS 2023*, 2023. doi: 10.48550/arXiv.2307.02483.
- Xiaoyan Wu, Chen Ren, Xiaoping Liu, and Chao Zhang. A motive cocktail in altruistic behaviors. *Nature Computational Science*, 2024. doi: 10.1038/s43588-024-00685-6.
- Erica J. Yoon, Michael Henry Tessler, Noah D. Goodman, and Michael C. Frank. Polite speech emerges from competing social goals. *Open Mind: Discoveries in Cognitive Science*, 4:71–87, 2020. doi: 10.1162/opmi_a_00035.
- Andy Zou, Zifan Wang, J. Kolter, and Matt Fredrikson. Universal and transferable adversarial attacks on aligned language models. *arXiv preprint*, 2023.