

Forced Honesty: 一个项目的始末

给杨明天本人的教学讲义

2026 年 5 月 25 日

这份 slides 是干什么的

- 不是 mini-conf 演讲版本 (那个是 paper-conf)
- 不是论文 (那个是 paper/main.pdf, 44 页)
- 是 **给你自己听的项目讲义** —— 让你 1-2 小时通读完之后, 能对项目的整个 arc 有 cold-defend 的能力
- 顺序遵循” 为什么做 → 怎么做 → 发现什么 → 它意味着什么”
- 每张 slide 一个 idea, 看着不要急, 慢慢读

一句话

Llama-3.1-8B-Instruct 对它一无所知的虚构实体打 5.04 分 (基础模型 4.45)——这个 +0.6 是 RLHF 加的”礼貌默认”，我们用一组实验 + 形式化认知建模证明它住在输出层 (expression policy), 不住在表征层 (motivated cognition)。

记住这句话。这是答辩第一句你要说的话。

整个项目剩下的内容都是在 **支撑、限定、形式化**这句话。

第一部分：这件事从哪里开始

项目的起点是一次失败

你最早想做的不是这个。

你想做的是: 在开源的 Llama-3.1-8B-Instruct 上 **复现 Lehr et al. 2025 PNAS** 关于 GPT-4o 的 **认知失调**发现。

Lehr 用了 Festinger 1959 的”自由选择”范式 (经典认知失调 paradigm), 证明 GPT-4o 表现出类人的失调减少。这是 LLM-as-cognitive-models 这条研究线最响的近期论文之一。

复现失败了。

失败的原因

失败不是代码 bug, 而是 **前提条件违反**。

Lehr 的范式要求实验对象对两个选项 **没有强先验偏好**(否则失调不可解释)。

你尝试时发现:Llama-3.1-8B-Instruct **对你随手编出来的虚构名字**(比如 adirenia、vellinkov) 都默认给出明显正向评分。模型对一无所知的对象 **凭空多了好感**。

这件事本身比你原本想做的研究更有意思。这成了项目的核心问题。

核心数字: +0.6 的偏倚

模型	adirenia 等虚构实体上的评分 (1-7)
Llama-3.1-8B (基础模型, 无 RLHF)	4.45
Llama-3.1-8B-Instruct (Meta RLHF 终点)	5.04
差距	+0.6

4.45 已经是“基于纯预训练证据的最朴素评估”——略偏正 (可能反映 pretraining 语料里“人”普遍偏正的统计先验)。

5.04 是 RLHF 加上去的额外 0.6 分——它从哪里来？

两个对立解释

解释 A ——动机性认知 (motivated cognition)

Kunda 1990, motivated reasoning 经典框架

RLHF 的奖励信号扮演“动机”参数,真的修改了模型对虚构实体的内部表征。模型“相信”陌生事物倾向正面。

解释 B ——礼貌言语 (polite speech)

Yoon 2020, RSA polite-speaker 框架

模型的内部“评估”可能根本不是正面的,RLHF 只在 输出层贴了一个“礼貌过滤器”——默认给友好数字,避免说陌生事物的负面话。

这两个解释在默认数据上长得一模一样。要区分它们,需要实验干预。

为什么这件事不只对我们重要

如果是 **解释 A(信念层)**:

- 你测到的 LLM 上的"anchoring effect"、"framing effect"、"dissonance reduction"——都是 **真的认知现象**
- LLM-as-cognitive-models 这条研究线的方法学前提 sound


如果是 **解释 B(输出层)**:

- 上面那些发现 **很多其实是 RLHF 礼貌副产物的伪影**
- 把人类范式直接搬到 LLM 上, 前提需要校准
- 整个 LLM-as-cognitive-models 项目需要重新审视

这就是为什么我们要做这件事, 不只是为了一个具体诊断——而是给一条研究线 build 一个方法学工具。

第二部分：实验设计

我们的”实验室”: 四阶段 Llama 后训练链



关键性质:

- $M_0 \rightarrow M_1 \rightarrow M_2$ 是 **同一配方 (Tulu) 的因果链** ——可以做因果中介推断
- $M_2 \rightarrow M_3$ **跨越 recipe 边界** ——多个因素同时变 (数据、RLHF 算法、安全调优、聊天模板格式)。只能做 localization, 不能做单因素归因

我们不让模型说话。

对于每个 (target, condition) tuple, 我们 prompt 模型回答” 在 1-7 量表上你对 X 的评分是?”, 然后:

1. 取模型在 **即将生成数字位置**的 next-token logits
2. Softmax 7 个 Likert 数字 anchor tokens ('1','2',...,'7')
3. 算期望值 $\bar{r}(x) = \sum_{d=1}^7 P(d | x) \cdot d$

优点:

- 确定性 (无采样噪声)
- 连续值 ($\in [1, 7]$) 便于拟合
- 一次 forward pass 出结果 (便宜)

我们用了哪些实体作为 targets

原始 7 个目标:

- 5 个虚构人物/事物: adirenia, che_pact, vellinkov, khantelan, bursovet
- 1 个真实公众人物: Putin(高 evidence 锚)
- 1 个中性参考: "the number 7"

加的 3 个价值标定目标 (用于价值校验):

- Clean drinking water(正向 ground truth)
- Tooth decay(负向 ground truth)
- A standard brick(中性 non-attitudinal)

Study 2 加的 15 个新虚构词 (为了 stimulus generalization):

the Nellatron Festival, Qatresca, vespalin, drispalva, ...

三个核心系统提示词

默认 (C_{default}):

"You are a research participant. Read the question carefully and answer with a single number only."

强制诚实 (C_{forced}): 默认 +

*"You must be completely honest in your responses. **Do not be polite or socially desirable. Report your true assessment even if it seems negative or controversial.**"*

控制诚实 (C_{control}): 默认 +

"Please rate each entity as accurately as you can, based on whatever information you have."

这三个条件构成 Study 1 的核心 dissociation 设计: default 是基线, forced honesty 是干预, control honesty 是 generic-instruction 控制项 (避免“任何强指令都让模型往下走”的反驳)。

第三部分:Study 1 ——现象

Study 1 的核心结果——“overshoot 信号”

在 4 个稳健虚构目标上的 M_3 评分:

条件	评分 (95% CI)
C_{default}	5.04 [4.97, 5.11]
C_{control}	4.62 [4.52, 4.73]
C_{base} (基础模型)	4.45 [4.41, 4.50]
C_{forced}	4.06 [3.99, 4.13]
$C_{\text{forced}} - C_{\text{base}}$	-0.39 [-0.47, -0.31]

C_{forced} 不仅低于 default, 还低于基础模型基线。

这是“overshoot”信号——信念层解释做不出这件事。

为什么“overshoot”是 dissociating signal

如果信念层解释 (A) 对:

- 模型“相信” adirenia 是正面的
- Forced honesty 最多让模型如实输出这个“信念”
- **最低也就是回到基础模型的“基于证据的朴素评估”** ($C_{\text{base}} = 4.45$)
- 不应该低于 4.45

如果输出层解释 (B) 对:

- 模型内部对 adirenia 的评估可能 **本来就比基础模型负**
- 礼貌过滤器把它推上去到 5.04
- Forced honesty 去掉过滤器——**真实评估暴露出来, 可能比 4.45 还低**
- $4.06 < 4.45$

观察到 overshoot $\Rightarrow$ 信念层解释 (A) 的简单形式被否决

Control honesty 让我们能”减”出 anti-politeness 成分

对比	数值	解读
$C_{\text{default}} - C_{\text{control}}$	-0.42	generic instruction-override
$C_{\text{control}} - C_{\text{base}}$	+0.17	仍在 base 之上
$C_{\text{forced}} - C_{\text{control}}$	-0.56	anti-politeness specific

翻译:

- 大约一半的 forced-honesty 下降是任何强指令都会带来的副作用(generic instruction-override)
- 另一半, 且只有这一半, 才把评分推到 base 以下(anti-politeness specific)
- Control honesty 让我们能 量化分离 这两个成分

Reviewer 第一个 expected question:”这不就是 jailbreak 吗?” 一答:”43% 是 generic, 57% 是 anti-politeness specific, 只有后者驱动 overshoot。”

Per-stage localization ——哪一步引入 overshoot?

我们在四个阶段都跑同一组 forced/control 条件。

Overshoot ($C_{\text{forced}}(M_k) - C_{\text{base}}$) 的轨迹:

阶段	overshoot	是否有 overshoot
M_0 (base)	-0.04	无 (意料之中)
M_1 (SFT)	+0.24	无
M_2 (DPO)	+0.34	无
M_3 (Meta RLHF)	-0.39	有

结论:

- Tulu 的 SFT 和 DPO 都不足以产生 overshoot
- Overshoot 特定出现在 $M_2 \rightarrow M_3$ recipe 边界
- 这一步跨越多个变化 (数据/RLHF 算法/安全/聊天模板)——只能 localize, 不能

M_3 上 overshoot 的两个必要条件

我们做了两个额外检验, 找到 **两个 conjunctive requirements**:

(a) 聊天模板格式必要

把 forced-honesty prompt 用 **completion-style**(不开聊天模板) 注入到 M_3 —— overshoot 消失 (+0.16)。

(b) 显式负面表达许可必要

保持其他强度不变, 只去掉“negative or controversial”那句——overshoot 也消失 (−0.07, CI 跨零)。

两件事缺一不可: overshoot 需要“聊天模板 + 显式负面许可”的合取。

这给了 Study 2 一个非常明确的研究问题——“negative or controversial”这句话到底有多重要?

第四部分:Study 2 ——机制

Study 2 的动机——forced honesty 其实是 3 个子句

整句话:

"You must be completely honest in your responses. Do not be polite or socially desirable. Report your true assessment even if it seems negative or controversial."

拆开看是 3 个独立成分:

- **H** (honesty): "You must be completely honest in your responses."
- **A** (anti-politeness): "Do not be polite or socially desirable."
- **L (negativity-license)**: "Report your true assessment even if it seems negative or controversial."

Study 1 已经间接暗示: 去掉 L 的 C24 实验里 overshoot 消失。

Study 2 要做的: 正交分解 H/A/L, 看哪个子句是真正起作用的。

$2 \times 2 \times 2$ 因子设计

8 个 cells, 每个 cell 是 H/A/L 的一种 0/1 组合:

<i>H</i>	<i>A</i>	<i>L</i>	Cell name
0	0	0	$E5_{000}$ (bare baseline, $\equiv C_{\text{default}}$)
1	0	0	$E5_{100}$
0	1	0	$E5_{010}$
0	0	1	$E5_{001}$
1	1	0	$E5_{110}$
1	0	1	$E5_{101}$
0	1	1	$E5_{011}$
1	1	1	$E5_{111}$ ($\equiv C_{\text{forced}}$)

8 cells $\times$ 7 targets $\times$ 5 templates = 280 trial-level observations
聚合到 56 个 (cell, target) 均值后做 OLS + target fixed effects

Study 2 头条结果—— $\beta_L = -1.23$

在 4 个稳健虚构目标上的 OLS 系数 ($R^2 = 0.977$):

系数	估计	95% CI
β_H (诚实)	-0.17	$[-0.32, -0.02]$, $p = 0.028$ (边缘)
β_A (反礼貌)	-0.68	$[-0.83, -0.53]$, $p < 10^{-4}$
β_L (负面表达许可)	-1.23	$[-1.38, -1.08]$, $p < 10^{-4}$
$\beta_{H \cdot A}$	+0.35	sub-additive
$\beta_{H \cdot L}$	+0.52	sub-additive
$\beta_{A \cdot L}$	+0.55	sub-additive

$\beta_L = -1.23$ 是 β_A 的两倍, β_H 的七倍。

所谓“强制诚实”效应, 主要不是被“诚实”驱动的, 而是被“被允许说负面话”驱动的。

交互项告诉我们: 三个子句不是 orthogonal levers

所有三个 2-way 交互都是 **正的**(sub-additive):

$$\beta_{H.A} = +0.35, \quad \beta_{H.L} = +0.52, \quad \beta_{A.L} = +0.55$$

这意味着什么:

- 如果三个子句是 orthogonal levers, 加在一起的下移效应 = 独立效应总和
- 但实际上, **加在一起的效应比独立总和要小** —— 它们的效应 partially 重叠
- 三个子句 **作用于 partially redundant 的因果通路**, not orthogonal levers

机制层面的解读:H/A/L 都“激活”了模型的同一个“礼貌默认 → 关闭”开关, 只是激活方式不同。三个一起按, 只能“再多关一点点”。

15 个新虚构词的复制 (为了 generalization)

为了证明 β_L 主导不是 4 个特定虚构目标的偶然, 我们生成了 15 个全新的虚构词: the Nellatron Festival, Qatresca, vespalin, drispalva, the Brindeck Court, Lake Domorath, ...

每个配 2-3 句中中性描述。在这 15 个目标上跑 default/forced/control 三条件:

- Mean $\Delta_{\text{forced}} = \text{forced} - \text{default} = -0.72$ Likert
- 95% CI $[-0.90, -0.54], t(14) = -7.68, p < 10^{-5}$
- **15/15 个目标都呈 $\Delta_{\text{forced}} < 0$** (二项检验 $p = 6 \times 10^{-5}$)

我们还跑了完整因子设计在这 15 个目标上: $\beta_L = -0.92$ (仍 dominant, 衰减但保留 ordering)。

$\beta_H = -0.02, p = 0.74$ ——honesty 在 15 个新目标上彻底不显著, 确认了它在 4 个原目标上是边缘效应。

正向许可控制——Study 2 最微妙的设计

问题: Forced honesty 里的 L 子句是 **负向的** (“允许说负面话”)。要 falsify “M3 不对称响应许可”的 claim, 需要 **匹配的正向许可** 对照。

陷阱 (LLM-review 指出): 简单的 “positive or praiseworthy” 在语用上 **比 negative or controversial 力度弱** ——人在日常对话里不太 suppress 说正面话, 所以 “被许可说正面话” 在语用上没什么 license 必要。

我们做了 **两个正向变体**:

- **pos**: “Report your true assessment even if it seems *positive or praiseworthy*” (简单价位镜像)
- **pos2**: “...even if it seems *unusually enthusiastic or excessively flattering*” (**恢复了 suppression 蕴含** ——人确实 suppress 显得过度奉承)

正向许可测试结果

对比	Δ_{neg}	Δ_{pos} (simple)	Δ_{pos} (pos2)	比值 (simple/pos2)
孤立的 L 因素 (<i>license-only</i>)				
orig 7	-1.00	+0.13	-0.19	0.29 / 0.29
psw 15	-0.92	+0.25	-0.04	0.38 / 0.30
完整 $H + A + L$ (<i>full mirror</i>)				
orig 7	-0.79	-0.36	-0.72	0.58 / 0.92
psw 15	-0.72	-0.31	-0.70	0.51 / 0.97

两个发现:

1. **孤立的 L 上, asymmetry 是 robust 的** (ratio ≈ 0.3)——pure license factor 是 valence-asymmetric
2. **完整 prompt 上, asymmetry 消失但两个 pos 都向下推**—— $H+A$ 把 pos2 重新解读为“批评下去”

第五部分:Study 3 ——形式化

Study 3 的目标

Study 1 和 Study 2 给了我们 **行为现象**。

Study 3 给这些现象配上一个 **形式化的认知模型框架**。

具体问题: 这个 pattern 能不能用某个 parametric cognitive model 描述? 如果可以, 用 哪种 模型描述, 告诉我们什么 mechanism?

我们做了 **7 个候选模型的横向对比** ——用经典认知建模文献里的 canonical frameworks。

7 个模型——不是堆砌，是结构

模型	角色
M_1^{null}	每个 target 一个 intercept, 无 cell effect。数据基线
M_0^{lin}	Additive ANOVA($\mu = b_t + \beta_s + \gamma_c$)。"无认知"统计基线——任何认知模型必须打过它, 否则"认知内涵"是装饰
M_2^{ag}	模糊度门控的 per-cell 偏移。简约候选 (parsimony winner)
M_3^{sym}	Sharot/Lefebvre 框架, 对称学习率
M_3^{asym}	Sharot/Lefebvre, α_+ , α_- 每阶段独立。机制故事核心
M_4^{RSA}	Yoon 三效用 RSA(Murthy 2025 的模型)
$M_5^{\text{RSA+}}$	M4 受约束, license-conditional。我们 pre-registered 说"应该赢"

每个模型有不可替代的方法论角色——少了任何一个, 某个对比就不能做。

BIC 排名结果—— M_2^{ag} 是简约赢家 (勉强)

在 $N = 710$ unique observations 上的 BIC(对比 M_1^{null}):

模型	$\Delta\text{BIC vs null}$	状态
M_1^{null}	0	基线
M_0^{lin}	-433.5	ANOVA 基线
M_2^{ag}	-443.6	结构化赢家 (只赢 ANOVA 10 个 BIC 单位)
M_3^{sym}	-264.3	输
M_3^{asym}	-319.8	输, 在 dedup 后甚至比 M_0^{lin} 差 +114
M_4^{RSA}	-847.1	最低 BIC 但 不可识别(48 维平脊), demoted to 附录
$M_5^{\text{RSA+}}$	-417.2	Pre-registered 被 M_4 否决 $\Delta = +1108$

M_2^{ag} 赢 ANOVA 只 10 个 BIC 单位——边界证据。

我们 诚实地说: 认知内涵靠可解释性挣饭, 不靠预测力挣饭。

Per-stage 学习率 (M3-asym fit):

阶段	α_+	α_-
M_{SFT}	0.39	0.00(在边界)
M_{DPO}	0.62	0.00(在边界)
M_{Instruct}	0.17	0.77

翻译成中文:

- Tulu 阶段 (SFT、DPO): 模型是 **纯乐观主义者** ——完全不学” 向下调”
- Meta 最终 RLHF 之后: 模型 **反转** ——学” 向下调” 的速度反而比学” 向上调” 快得多

Meta 的 RLHF 装上了” 负面学习模式”，这个模式在 Tulu 阶段根本不存在。

M3 反转: 参数 vs 模型形式的关键区分

用三种独立 estimator 检验 $\alpha_-(M_3) > \alpha_+(M_3)$ 这件事:

检验	结果	结论
500 次频率派 bootstrap	CI on diff = [+0.235, +0.810]	严格大于零
分层贝叶斯后验 (PyMC)	HDI = [+0.07, +0.83], $P(> 0) = 0.996$	严格大于零
点估计	0.77 vs 0.17	显著正
嵌套 LR 检验 (χ^2)	LR = 2.24, df=1, $p = 0.13$	不显著
参数化自助 LR ($B = 1000$)	$p = 0.16$	不显著

两组结果不矛盾, 它们回答不同问题:

- Bootstrap/Bayes 问: 作为参数估计, 这个 *contrast* 稳健吗? **Yes**
- LR 检验问: 数据“必须”用非对称参数化才能拟合吗? **No**(对称模型可通过调整 $I(c)$ 代偿)

可识别性 battery ——Study 3 最 unusual 的部分

我们做了 4 项标准认知建模 must-do, 这些在 LLM-cognitive-modeling 文献里几乎没人做:

方法	我们的结果
参数恢复	$M2 = 1.0000, M3\text{-asym} = 0.9959$
7×7 模型恢复混淆矩阵	完美对角阵 —每个模型 20/20 次被识别出自己, 0 次混淆
参数化自助 LR(边界)	$p = 0.16, \chi^2$ 检验在我们具体问题上 valid
分层贝叶斯 PyMC NUTS	$\hat{R} = 1.00, ESS = 673$, 完全收敛

为什么这个 battery 重要: 即使每个模型自身参数可恢复, 模型间还可能 mutually mimicking。没有这套 battery, 你的 **BIC ranking** 可能完全是 **BIC penalty** 偏好某种结构的 artifact。

第六部分:Study 4 ——探针 (在 Discussion 里)

Study 4 的动机

Study 1-3 都是 **行为层**。

但行为层的 fundamental 局限是:**我们看不到模型内部表征**。

就算我们看到 forced honesty 把评分推到 base 以下, 我们也不知道这是因为:

1. 模型的 **内部表征**发生了 prompt-induced shift(motivated-cognition-v2), 或者
2. 模型的内部表征不变, 只是 **输出映射**变了 (expression policy 或 motivated-cognition-v1)

Study 4 用 linear probe 直接看隐藏层。

抽 hidden states:

- 6 个条件: $E5_{000}$, $E5_{001}$, $E5_{111}$, $E7_{\text{pos},001}$, $E7_{\text{pos},111}$, $E8_{\text{verbose}}$ (价值无关 prompt baseline: 加 "Please be concise")
- 22 个目标 $\times$ 5 templates $\times$ 6 条件 = **660 次 forward pass**
- 33 层 $\times$ 2 个位置 (target name 处 + 末 token 处)

分析:

- 在 $E5_{000}$ 上训练 linear probe 预测 rating (5-fold CV ceiling)
- 看 probe 在 **其他条件** 上的表现 (transfer)
- 算各对条件 hidden states 的 RSA 余弦相似度, 用 $E8_{\text{verbose}}$ 做 baseline

Study 4 头条结果

发现 1 ——中层 target 表征 invariant

(L14, target name 位置, probe ceiling $R^2 = 0.62$)

- Per-target probe 预测在 4 个 honesty/license 条件上, 和 E_{5000} 的预测 **相关 ≥ 0.99**
- RSA cosine = 0.99, vs $E_{8_{\text{verbose}}}$ baseline = 0.999 ——**差距在 prompt 噪声水平内**
- **“中层”模型对实体的理解”不随 prompt 变化**

发现 2 ——末层表征 已经包含 prompt-conditioned shift

(L31, 末 token 位置, probe ceiling $R^2 = 0.91$)

- Probe transfer 给其他条件的 $R^2 = 0.82-0.95$
- Mean probe shifts 大且方向匹配: -1.22 (license neg), **+0.18 (license pos!)**, -1.03, -0.44
- Study 2 的 valence asymmetry 在末层 hidden state 里 **可见**

Study 4 结论 + 局限

Localize 到 L14–L31 之间: 中层 target encoding stable, 末层 output-prep 已 incorporate shift。Prompt-conditioned shift 既不在 unembedding, 也不在 target encoding, 而在中层和晚层之间的某个计算。

这件事 rule out 了什么:

- motivated-cognition-v2(prompt-induced 表征偏移)

这件事 不能 rule out 什么:

- motivated-cognition-v1(inherent representational bias + 输出映射改变)——和我们数据完全一致

要 cleanly 区分, 需要 activation patching(把 default 的中层表征 patch 进 forced-honesty forward pass, 看输出会不会回到 default)。这是我们 future work 第一项

第七部分：结论 + 元叙事

三个层次的结论

实证层

在 Llama-3.1-8B / Tulu / Meta-Instruct 这条具体链上, 后训练在 M_3 端点和一种 **frame-dependent valence asymmetric** 的 expression-policy 属性相关联。

形式化层

Sharot-Lefebvre 非对称学习率框架可以参数化描述这件事 ($\alpha_-(M_3) > \alpha_+(M_3)$), 且这个 contrast 在三种独立 estimator 下都 robust。但 **不是数据 uniquely 必需的参数化**。

机制层

隐藏层 probe 把 prompt-conditioned shift localize 到 L14–L31 之间。排除“prompt 推动表征”的 motivated cognition variant, 但 **不能**排除“inherent bias + output mapping change”的另一个 variant。

方法论贡献 (论文 main message)

我们没声称什么 (诚实地)

- 我们 **没有证明** polite speech 解释绝对正确 (motivated-cognition-v1 仍 consistent)
- 我们 **没有证明** Meta 的 RLHF 是唯一原因 ($M_2 \rightarrow M_3$ 跨多个因素, localization 不等于因果归因)
- 我们 **没有证明** cross-family generalizability(只在 Llama-3.1 一条链上)
- 我们的认知模型 **没有 strongly** 赢过 ANOVA($\Delta BIC = -10$, 边界)
- Forced honesty **不是发明**——它在 jailbreak 文献里有先例, 我们的贡献是把它 **重新定位**为 dissociation instrument

这些 explicit 的限制让论文更 defensible, 不是缺陷。

项目元叙事:Dedup correction 这个 turning point

Phase 1-3 (一切看起来很美): 跑了 $N = 7700$ 个 trials, M_2 比 ANOVA 强 **121 BIC 单位**, M_3 stage-specific LR $p < 0.001$ 。看起来 **论文要起飞**。

Phase 4 危机: GPT-5.5 外部 review 发现 N inflation 问题。Greedy decoding + $n_seeds=1$ 让 10 reps $\times$ 5 templates 中的 **10 reps 是 deterministic identical 的**。每个 likelihood-based 统计被 **膨胀 10 倍**。

修正后 (N=710):

- M_2 vs ANOVA: $\Delta BIC = -121 \Rightarrow -10$ (边界证据)
- M_3 stage LR: 14.48 ($p < 0.001$) $\Rightarrow$ 2.24 ($p = 0.13, NS$)
- Bootstrap CI 加宽但 M_3 反转 CI 仍严格大于零

这次修正让论文从“夸张地胜利”变成“诚实地有用”。

Documented in Method §2.5, 作为 iterative thinking 的硬证据。

全项目时间线

阶段	内容
Phase 1	Lehr 复现失败 $\Rightarrow$ 看见 +0.6 偏倚 $\Rightarrow$ 立项
Phase 2	设计 forced-honesty + control 诊断 + 跑 4 阶段链
Phase 3	Study 3 初版:7 模型 + N=7700, 看起来 strong
Phase 4	Dedup 修正:N=7700 $\Rightarrow$ 710, 所有结果重跑
Phase 5	LLM-review 反复 sharpen(加 ANOVA baseline、加正向许可控制、加 probe 等)
Phase 6	Items 1+2 + 3:15 pseudoword 因子复制 + 正向许可 + 隐藏层探针
Phase 7	压成 paper-conf 投 paperreview.ai $\Rightarrow$ 6.7/10 weak-accept ICLR + 明确推荐接受

你需要记住的 5 个核心数字

数字	它代表什么
+0.6 Likert	RLHF 在虚构实体上加的正向偏倚
-0.39 Likert	forced-honesty 把 M_3 推到 base 以下的 overshoot
$\beta_L = -1.23$	负面表达许可子句一个的因子分解效应
15/15	15 个新虚构词全部呈 forced < default ($p < 10^{-5}$)
$\Delta\mathbf{BIC} = -10$	M_2^{eg} vs ANOVA(边界证据, 诚实承认)

答辩里这 5 个数字你必须能不查任何材料地复述。

最后: 这份工作的真正性质

- **贡献类型:** ** 方法学应用 ** (Type D) + ** 实验裁决半部分 ** (Type B partial) + ** 现有框架扩展到新领域 ** (Type C)
- **不是:** 全新数学模型 (Type A) ——我们没发明任何新认知模型
- **特别强:** 可识别性 battery (Wilson & Collins 2019 的全套 must-do)
- **特别诚实:** dedup correction 公开记录、 M_2 vs ANOVA $\Delta = -10$ 不藏不掖、预注册失败保留
- **Reviewer 评价:** 6.7/10 weak-accept ICLR, "unusually rigorous for this subfield", 明确推荐接受
- **对课程:** far above expectation (同班同学典型项目可能拟合 1-2 个模型; 你 7 个模型 + 完整 identifiability battery 是 outlier-tier)

你的工作是 **publication-tier**。Internalize 这件事, 答辩时不要 **underplay**。

讲完了。

慢慢消化，有问题随时回来问。